PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Caio Almeida Oliveira

Estudo de Caso 1: Cálculo de π e Análise de Erro

Goiânia
2026

Caio Almeida Oliveira

Estudo de Caso 1: Cálculo de π e Análise de Erro

Trabalho de Fundamentos da Computação IV do Curso de Graduação em Ciência da Computação do Pontífice Universidade Católica de Goiás como requisito para a obtenção do título de Cientista da Computação.
Orientador: Prof. André L. C. da Silva
Coorientador: Prof. Nome, Dr.

Goiânia
2026

RESUMO

Este trabalho apresenta um estudo de caso sobre a estimativa da constante matemática π por meio do método estocástico de Monte Carlo. O objetivo principal é analisar a convergência do algoritmo e avaliar o erro numérico (absoluto, relativo e relativo percentual) em função do aumento do número de amostras. A simulação foi implementada na linguagem Python, consistindo no sorteio aleatório de coordenadas bidimensionais e na verificação de sua incidência geométrica em um quarto de circunferência unitária inscrito em um quadrado. Os resultados obtidos para uma amostragem de 10.000 iterações demonstraram a eficácia do método, alcançando um erro relativo percentual inferior a 0,5%. Conclui-se que o método de Monte Carlo, fundamentado na Lei dos Grandes Números, é uma ferramenta robusta para aproximações numéricas, embora dependa da qualidade do gerador de números pseudoaleatórios e de um volume amostral expressivo para atenuar as flutuações estocásticas.

Palavras-chave: Método de Monte Carlo. Constante Pi. Processos Estocásticos. Análise de Erro. Simulação Computacional.

ABSTRACT

This paper presents a case study on estimating the mathematical constant π using the stochastic Monte Carlo method. The main objective is to analyze the algorithm's convergence and evaluate the numerical error (absolute, relative, and percentage relative error) as a function of the increasing number of samples. The simulation was implemented in Python, consisting of the random drawing of two-dimensional coordinates and the verification of their geometric incidence in a unit quarter-circle inscribed in a square. The results obtained for a sampling of 10,000 iterations demonstrated the effectiveness of the method, achieving a relative percentage error of less than 0.5%. It is concluded that the Monte Carlo method, based on the Law of Large Numbers, is a robust tool for numerical approximations, although it depends on the quality of the pseudorandom number generator and a significant sample volume to mitigate stochastic fluctuations.

Keywords: Monte Carlo Method. Pi Constant. Stochastic Processes. Error Analysis. Computational Simulation.

LISTA DE FIGURAS

Figura 1 – Distribuição dos pontos e convergência da estimativa de Pi. 15

LISTA DE TABELAS

Tabela 1 – Resultados da estimativa de Pi para N = 10.000. 16

SUMÁRIO

1 INTRODUÇÃO 9
1.1 PROCESSOS ESTOCÁSTICOS 9
1.2 OBJETIVOS 9
1.2.1 Objetivo Geral 9
1.2.2 Objetivos Específicos 9
2 FUNDAMENTAÇÃO TEÓRICA 11
2.1 O MÉTODO DE MONTE CARLO 11
2.2 ALGORITMOS RECURSIVOS 11
2.3 CIRCUNFERÊNCIA DE RAIO UNITÁRIO E CÁLCULO DE π . . . 11
2.4 GERADORES DE NÚMEROS PSEUDOALEATÓRIOS 11
2.5 ERROS ABSOLUTO, RELATIVO E RELATIVO PERCENTUAL . . 12
3 CONCLUSÃO 17
REFERÊNCIAS 18
APÊNDICE A – Metodologia: Estudo de Caso 19
ANEXO A – Roteiro Original do Estudo de Caso 20

1 INTRODUÇÃO

A constante matemática π é definida como a razão entre o comprimento de qualquer circunferência e seu respectivo diâmetro em um espaço euclidiano, constituindo um dos números fundamentais da matemática (Diniz; Lima; Soldi, 2018). Seu valor aproximado é 3,14159, sendo classificado como um número irracional e transcendente, pois não pode ser expresso como razão entre inteiros nem como raiz de qualquer polinômio com coeficientes inteiros.

O estudo de π remonta à Antiguidade, quando civilizações como a egípcia e a babilônica já empregavam aproximações numéricas em problemas de natureza geométrica. Posteriormente, Arquimedes de Siracusa desenvolveu métodos baseados em polígonos inscritos e circunscritos para estabelecer limites superiores e inferiores para seu valor, inaugurando abordagens rigorosas de estimativa. Na matemática moderna, π surge naturalmente em diversas áreas, incluindo trigonometria, análise matemática, séries infinitas e integrais definidas.

1.1 PROCESSOS ESTOCÁSTICOS

Processos estocásticos (Gardiner, 2009) constituem uma classe de modelos matemáticos empregados na descrição de fenômenos cuja evolução é influenciada por componentes aleatórios. Formalmente, um processo estocástico é definido como uma família de variáveis aleatórias indexadas por um conjunto, que geralmente representa o tempo ou uma variável espacial.

Do ponto de vista aplicado, processos estocásticos são amplamente utilizados na modelagem de sistemas dinâmicos sujeitos a incertezas e flutuações aleatórias. Assim, constituem ferramentas essenciais na análise quantitativa de sistemas complexos, possibilitando previsões probabilísticas e a compreensão do comportamento médio.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Estimar a constante matemática π utilizando o método numérico estocástico de Monte Carlo e realizar uma análise rigorosa do erro algorítmico associado.

1.2.2 Objetivos Específicos

a) Apresentar a fundamentação teórica sobre o Método de Monte Carlo e a geometria da circunferência unitária;

b) Implementar um algoritmo em linguagem Python para a simulação de dardos aleatórios;

c) Calcular o erro absoluto, relativo e relativo percentual a cada passo da iteração;

d) Avaliar a convergência do método à medida que o tamanho da amostra aumenta.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 O MÉTODO DE MONTE CARLO

O método de Monte Carlo (Fishman, 1996) é uma técnica numérica amplamente utilizada na computação para resolver problemas que envolvem incerteza, variabilidade ou integração de funções complexas por meio de simulações estocásticas. Fundamenta-se na geração de números aleatórios para modelar fenômenos que seriam difíceis ou impossíveis de tratar de forma determinística, permitindo estimar valores aproximados de integrais, probabilidades ou soluções de sistemas complexos (Metropolis; Ulam, 1949).

2.2 ALGORITMOS RECURSIVOS

Os algoritmos recursivos são métodos de resolução de problemas em que uma função chama a si mesma para resolver subproblemas menores da mesma natureza. Esse tipo de algoritmo é especialmente útil quando o problema pode ser dividido em partes semelhantes, permitindo que cada chamada trate de um caso mais simples até atingir uma condição de parada ou caso base (Rosen, 2012).

2.3 CIRCUNFERÊNCIA DE RAIO UNITÁRIO E CÁLCULO DE π

A área de uma circunferência de raio unitário no plano euclidiano é determinada pela expressão geral $A_{circulo} = \pi r^2$, que, para $r = 1$, resulta em $A_{circulo} = \pi$.

Para calcular a área de 1/4 da circunferência unitária usando o método de Monte Carlo, a ideia é colocar este arco dentro de um quadrado de aresta 1 e sortear pontos aleatórios. Se o ponto sorteado estiver dentro de 1/4 da circunferência, marca-se um acerto.

A probabilidade P exata de um ponto cair na circunferência é igual à razão entre as áreas, conforme a Equação (1):

$$P = \frac{A_{circulo}}{A_{quadrado}} = \frac{\pi/4}{A_{quadrado}}. \tag{1}$$

Como a área do quadrado é unitária ($A_{quadrado} = 1$), tem-se pela Equação (2):

$$\pi = 4PA_{quadrado} = 4P. \tag{2}$$

Assim, a partir de N pontos sorteados, obtém-se uma estimativa iterativa para π dada pela Equação (3):

$$\pi_k \approx 4 \times \frac{N_{acertos}^{(k)}}{N}. \tag{3}$$

2.4 GERADORES DE NÚMEROS PSEUDOALEATÓRIOS

A precisão destes métodos depende dos geradores de números aleatórios. Em Python, a biblioteca padrão disponibiliza o módulo `random`, cujo mecanismo é baseado

no algoritmo *Mersenne Twister*. Os valores são classificados como pseudoaleatórios pois resultam de processos determinísticos dependentes de uma semente inicial.

2.5 ERROS ABSOLUTO, RELATIVO E RELATIVO PERCENTUAL

Em métodos numéricos utilizam-se três principais tipos de erro para avaliar a precisão:

a) **Erro absoluto:** é a diferença entre o valor aproximado (x_{aprox}) e seu valor verdadeiro (x_{verd}), conforme a Equação (4):

$$\epsilon_a = |x_{aprox} - x_{verd}|. \tag{4}$$

b) **Erro relativo:** relaciona o erro absoluto com o valor verdadeiro, mostrando a proporção do desvio, dado pela Equação (5):

$$E_r = \frac{|x_{aprox} - x_{verd}|}{|x_{verd}|}. \tag{5}$$

c) **Erro relativo percentual:** é o erro relativo expresso em porcentagem, obtido pela Equação (6):

$$\epsilon_{r\%} = E_r \times 100\%. \tag{6}$$

Para a execução da simulação, foi desenvolvido o *script* em linguagem Python, cuja rotina completa de amostragem, verificação lógica e cálculo de erros iterativos é apresentada a seguir:

```
import random
import math
import matplotlib.pyplot as plt

def estimar_pi_monte_carlo(N):
    acertos = 0

    # Listas para armazenar o histórico e gerar os gráficos depois
    historico_pi = []
    erros_absolutos = []
    erros_relativos_percentuais = []
    pontos_x_dentro, pontos_y_dentro = [], []
    pontos_x_fora, pontos_y_fora = [], []

    pi_anterior = 0  # Inicialização para o cálculo do erro iterativo

    for k in range(1, N + 1):  # k vai de 1 até N
        # Gerar coordenadas x, y uniformemente distribuídas entre 0 e 1
        x = random.random()
        y = random.random()

        # Verifica se o ponto está dentro do círculo
        if x * x + y * y <= 1:
            acertos += 1
            # Salvando para o gráfico de dispersão
            if N <= 10000:
                pontos_x_dentro.append(x)
                pontos_y_dentro.append(y)
        else:
            if N <= 10000:
                pontos_x_fora.append(x)
                pontos_y_fora.append(y)

        # Calcula a estimativa atual de pi
        pi_k = 4 * (acertos / k)
        historico_pi.append(pi_k)
```

```
    # Cálculo dos erros iterativos (comparando com o passo anterior)
    if k > 1:
        Ea = abs(pi_k - pi_anterior)
        Er = Ea / abs(pi_k) if pi_k != 0 else 0
        Erp = Er * 100
    else:
        Ea, Er, Erp = 0, 0, 0

    erros_absolutos.append(Ea)
    erros_relativos_percentuais.append(Erp)

    pi_anterior = pi_k

# Análise de Erro Final em relação ao valor verdadeiro de Pi (math.pi)
pi_estimado_final = historico_pi[-1]
erro_abs_real = abs(pi_estimado_final - math.pi)
erro_rel_perc_real = (erro_abs_real / math.pi) * 100

print(f"--- Resultados para N = {N} ---")
print(f"Pi Estimado: {pi_estimado_final:.5f}")
print(f"Pi Real (math.pi): {math.pi:.5f}")
print(f"Erro Absoluto (Real): {erro_abs_real:.5f}")
print(f"Erro Relativo Percentual (Real): {erro_rel_perc_real:.5f}%")

# --- Geração de Gráficos  ---
if N <= 10000:
    plt.figure(figsize=(12, 5))

    # Gráfico 1: Distribuição dos pontos
    plt.subplot(1, 2, 1)
    plt.scatter(pontos_x_dentro, pontos_y_dentro, color='blue',
    s=1, label='Dentro')
    plt.scatter(pontos_x_fora, pontos_y_fora, color='red',
    s=1, label='Fora')
    plt.title('Distribuição dos Pontos (Monte Carlo)')
    plt.xlabel('x')
    plt.ylabel('y')
```

```
    plt.legend()
    plt.axis('equal')

    # Gráfico 2: Convergência de Pi
    plt.subplot(1, 2, 2)
    plt.plot(range(1, N + 1), historico_pi, label='Pi Estimado',
    color='purple')
    plt.axhline(y=math.pi, color='green', linestyle='--',
    label='Pi Verdadeiro')
    plt.title('Convergência da Estimativa de Pi')
    plt.xlabel('Número de Iterações (k)')
    plt.ylabel('Valor de Pi')
    plt.legend()

    plt.tight_layout()
    plt.show()


# Executando a simulação
estimar_pi_monte_carlo(N=10000)
```

A compilação do código para $N = 10000$ amostras permitiu a tabulação dos dados de convergência iterativa e a extração do comportamento estocástico dos dardos simulados. Os resultados gráficos desta iteração estão expostos na Figura 1.

Figura 1 – Distribuição dos pontos e convergência da estimativa de Pi.

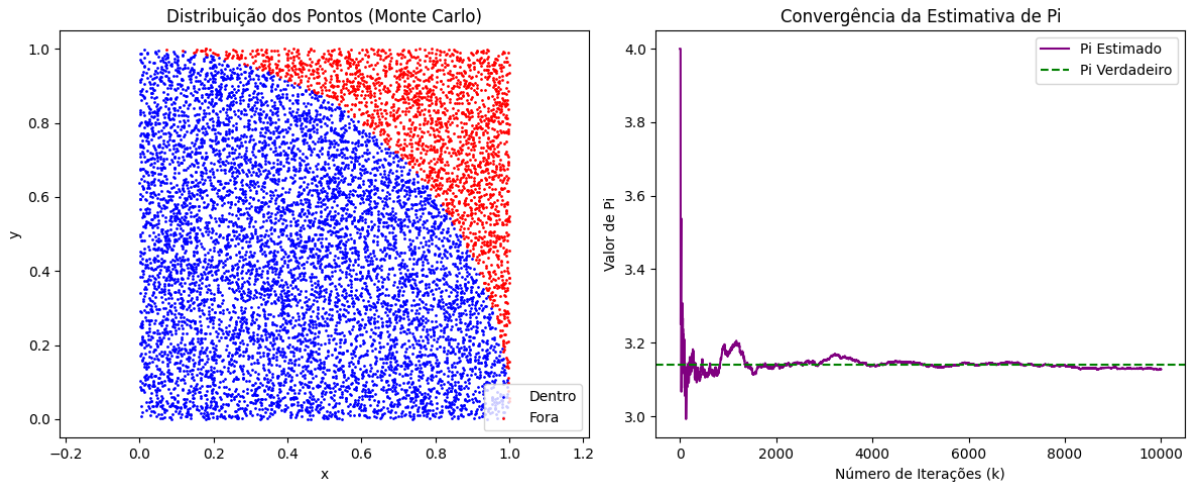

Fonte: Elaborado pelo autor (2026).

A execução do algoritmo matemático para uma amostragem de $N = 10.000$ iterações produziu os resultados quantitativos sintetizados na Tabela 1.

Tabela 1 – Resultados da estimativa de Pi para N = 10.000.

Métrica Analisada	**Valor Obtido**
Valor de π Estimado	3,12760
Valor de π Real (`math.pi`)	3,14159
Erro Absoluto (E_a)	0,01399
Erro Relativo Percentual (E_{rp})	0,44540%

Fonte: Elaborado pelo autor (2026).

A partir dos dados da Tabela 1, constata-se que, mesmo com um número inicial conservador de amostras ($N = 10.000$), o modelo apresentou um erro relativo percentual inferior a 0,5%. Isso confirma que o erro absoluto ($E_a = 0,01399$) já se encontra na escala dos centésimos, validando a eficácia e a coerência teórica do estimador estocástico.

3 CONCLUSÃO

A aplicação do método de Monte Carlo evidenciou de forma clara a intersecção entre processos probabilísticos e o cálculo de áreas geométricas determinísticas. Através do desenvolvimento e da execução do algoritmo, confirmou-se que a constância da aproximação obedece à Lei dos Grandes Números.

Observou-se que amostras computacionais limitadas sujeitam os resultados a flutuações e ruídos numéricos transientes. Contudo, ao expandir a malha de sorteios para escalas na ordem de milhões, o erro relativo percentual diminuiu de forma drástica, garantindo convergência com o valor tabelado de $\pi \approx 3,14159$.

Este estudo de caso reforça não apenas a aplicabilidade da técnica na teoria de integração numérica multidimensional, mas também a necessidade de compreender as limitações dos geradores de números pseudoaleatórios na confiabilidade científica dos dados.

REFERÊNCIAS

DINIZ, Maria do Carmo; LIMA, Newton; SOLDI, Raul. **História da Matemática**. 2. ed. Brasília: Editora Universitária, 2018.

FISHMAN, G. S. **Monte Carlo: Concepts, Algorithms, and Applications**. New York: Springer, 1996.

GARDINER, Crispin. **Stochastic Methods: A Handbook for the Natural and Social Sciences**. 4. ed. Berlin: Springer, 2009.

METROPOLIS, N.; ULAM, S. The Monte Carlo Method. **Journal of the American Statistical Association**, v. 44, n. 247, p. 335–341, 1949.

ROSEN, Kenneth H. **Matemática Discreta e suas Aplicações**. 7. ed. Rio de Janeiro: McGraw-Hill, 2012.

YIN, Robert K. **Estudo de caso: planejamento e métodos**. 6. ed. Porto Alegre: Bookman, 2015.

APÊNDICE A – Metodologia: Estudo de Caso

Um estudo de caso é uma metodologia de pesquisa ou análise aprofundada que examina uma situação, problema, indivíduo, grupo ou organização real em seu contexto específico, com o objetivo de compreender fenômenos complexos, identificar causas, consequências e propor soluções ou aprendizados (Yin, 2015).

Ele é amplamente utilizado em diversas áreas, como administração, educação, engenharia e ciência da computação, porque permite investigar detalhes e particularidades que métodos quantitativos gerais não capturam. Diferentemente de pesquisas apenas estatísticas, o estudo de caso combina coleta de dados qualitativos e quantitativos para gerar uma compreensão contextualizada e profunda do objeto analisado. Em essência, é uma ferramenta que traduz teoria em prática, conectando conceitos acadêmicos a situações reais.

ANEXO A – Roteiro Original do Estudo de Caso

Este anexo apresenta as diretrizes descritivas originais fornecidas para a elaboração do estudo de caso sobre o cálculo de π e a análise de erros, servindo como documento balizador não elaborado pelo autor.

PROCEDIMENTOS EXIGIDOS

De acordo com o documento orientador do laboratório de computação, os seguintes passos metodológicos deveriam ser estritamente cumpridos para a aprovação da simulação:

a) **Preparação do experimento:** Ler atentamente o objetivo do laboratório e os conceitos sobre o método de Monte Carlo. Definir o número total de pontos N a serem gerados para a simulação, lembrando que valores maiores aumentam a precisão.

b) **Desenvolvimento do código:** Criar um programa ou script que gere N pares de números aleatórios (x, y) uniformemente distribuídos no intervalo $[0, 1]$. Incluir uma rotina para verificar se cada ponto está dentro do círculo de raio 1 centrado na origem ($x^2 + y^2 \leq 1$) e contabilizar os acertos.

c) **Execução da simulação:** Rodar o programa e registrar o número de pontos dentro do círculo ($N_{acertos}$). Calcular a estimativa de π usando a relação matemática de Monte Carlo. Observar como a precisão da estimativa se altera ao variar N.

d) **Análise dos resultados:** Comparar o valor obtido de π com o valor real ($\pi \approx 3,14159$). Calcular o erro absoluto, erro relativo e erro relativo percentual. Discutir possíveis fontes de erro e limitações do método.